南通大學



本科毕业设计

题目	主动推断作为意识的计算框架研究

学生姓名： 朱昌波

专　　业： 机器人工程

指导教师： X** 教授

完成日期： 2026 年 5 月 30 日

诚　信　承　诺　书

本人承诺：所呈交的毕业设计是本人在导师指导下进行的研究成果。除了文中特别加以标注和致谢的地方外，其中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他同志对本研究所做的任何贡献均已在文中作了明确的说明并表示了谢意。

学生签名：_____ 日期：_____

本论文使用授权说明

本人完全了解南通大学有关保留、使用学位论文的规定，即：学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

（保密的论文在解密后应遵守此规定）

学生签名：_____ 指导教师签名：_____ 日期：_____

摘　　要

指纹在生物识别应用中的形式最为广泛，具有唯一性和不变性。指纹增强的主要任务是恢复指纹脊线的结构缺陷，其目的是通过改善指纹脊线质量来提高指纹特征提取的精度，进而提高指纹识别的精度。

在系统研究指纹增强算法的基础上，介绍了指纹增强的研究背景及现状，论述了指纹增强的概念及指纹增强的各种实现方法。除空间域增强和频域增强外，重点介绍了 Gabor 滤波器在指纹增强技术中的应用，并且在此基础上提出了改进算法。仿真显示 Gabor 滤波法在指纹增强技术中具有很好的带通特性，也具有很好的方向和频率选择特性。因此，用 Gabor 滤波器对原始指纹图像进行滤波可以有效地去除脊线方向的噪声，保存真实的脊线结构。Log-Gabor 滤波法作为改进算法，弥补了 Gabor 滤波法的缺陷，改善指纹图像的滤波效果。

关键词：指纹增强，脊线方向，脊线频率，Gabor 滤波

ABSTRACT

In biometric identification, the most widely used form was the fingerprint, which has unique and invariable property. The main task of fingerprint enhancement was to restore the structural defects of its ridge. The ultimate goal was to improve the accuracy of fingerprint feature extraction by improving the quality of the ridge, leading to improving the accuracy of fingerprint identification.

Based on the fingerprint enhancement algorithms, the paper introduced the research background, actuality of fingerprint enhancement, the concept of fingerprint enhancement and various implementation methods. Other than spatial and frequency domain enhancement, the paper focused on introducing the Gabor filter in fingerprint image enhancement techniques and putting forward some improved algorithms. The Gabor filtering has nice band pass ability in fingerprint enhancement from simulation results, with nice direction and frequency selectivity. Thus, Gabor filtering can effectively remove the noise of the ridge along its direction, also save the true ridge structure. As an improved algorithm, Log-Gabor filter which can make up the defect of Gabor filter improves the final effect of filtering.

Key Words: Fingerprint enhancement, Ridge orientation, Ridge frequency, Gabor filtering

目 录

摘 要 I
ABSTRACT III
第一章 绪论 1
1.1 课题来源、研究的目的和意义 1
1.2 国内外研究概况 1
1.2.1 国外研究概况 1
1.2.2 国内研究概况 1
1.3 论文的主要研究内容 1
第二章 材料与方法 3
2.1 研究资料及仪器设备 3
2.1.1 研究对象 3
2.1.2 主要仪器与试剂 3
2.2 实验流程与方法 3
2.2.1 标本制作 3
2.2.2 获取数据 3
2.2.3 分析数据 3
2.2.4 测定数据 3
2.2.5 统计学处理 3
第三章 结果 5
3.1 软件分析 5
3.2 数据获取 5
第四章 结论与展望 7
4.1 论文总结 7
4.2 未来工作展望 8
参考文献 9
致 谢 11
附录 A 矩阵分析 13
A.1 向量变元的梯度 13

第一章　绪论

1.1　课题来源、研究的目的和意义

临床上，慢性疼痛是一类发病率很高的疾病，大约占成年人群的 30%。全世界每年用于疼痛治疗的费用高达数千亿美元，目前临床上使用的镇痛手段对神经病理性疼痛和癌症痛等顽固性疼痛的疗效非常有限，迫切需要开发新的更为有效的治疗手段。因此，痛觉研究成为神经科学的前沿课题之一。

1.2　国内外研究概况

1.2.1　国外研究概况

临床上，慢性疼痛是一类发病率很高的疾病，大约占成年人群的 30%。全世界每年用于疼痛治疗的费用高达数千亿美元，目前临床上使用的镇痛手段对神经病理性疼痛和癌症痛等顽固性疼痛的疗效非常有限，迫切需要开发新的更为有效的治疗手段。因此，痛觉研究成为神经科学的前沿课题之一。

1. 加拿大的... ...。
2. ... ...

1.2.2　国内研究概况

国内还没看到相关方面的报道……现在所通用的 NC 代码[1] ... ...

1.3　论文的主要研究内容

本论文是以作者攻读硕士学位期间承担课题的工作为基础...

第二章　材料与方法

2.1　研究资料及仪器设备

… …

2.1.1　研究对象

… …

2.1.2　主要仪器与试剂

… …

2.2　实验流程与方法

2.2.1　标本制作

2.2.2　获取数据

2.2.3　分析数据

2.2.4　测定数据

2.2.5　统计学处理

第三章　结果

3.1　软件分析

现在主流的 CAM 软件（如 Catia，Pro/Engineer），由于……

3.2　数据获取

什么组: 自 2006 年 9 月至 2007 年 2 月，入院的什么脑损伤什么 38 例。入选标准: 经病史、体检和 CT 扫描确诊，除外肝肾血液疾病史以及伴有多脏器损伤什么。按 GCS 格拉斯哥评分，进行分类: 重症按 GCS 格拉斯哥评分，进行分类: 重症按 GCS 格拉斯哥评分，进行分类: 重症按 GCS 格拉斯哥评分，，进行分类: 重症什么 20 例 (GCS3-8 分)，男 17 例、女 3 例，男 16 例、女 2 例，年龄 16-78 岁。性别、年龄无显著性差异。损伤类型，重症组 20 例中: 硬膜外血肿 4 例、硬膜下血肿 7 例、多发性什么内血肿 4 例、脑内血肿 2 例、脑挫裂伤 3 例; 轻症组 18 例中: 硬膜外血肿 5 例、硬膜下血肿 5 例、脑挫裂伤 8 例。什么方式，常规脱水止血抗炎什么。需手术的行手术什么。重症组施行什么内血肿清除术 13 例，保守什么 7 例; 轻症组施行什么内血肿清除术 6 例、保守什么 12 例。(表 3-1)

表 3-1　正常组小鼠各主要组织的砷分布

脏器	砷含量（$\bar{X} \pm S, \mu g/g$）
大脑	BDL
肺	0.1023 ± 0.0659
心脏	BDL

BDL：低于检出限

目前 HCCI 数值模拟研究主要集中在单区、多区和多维模型上[2]。本节将从这三方面分别予以介绍：

1. 单区模型

公式应另起一行，正文中的公式、算式或方程式等应编排序号，公式的编号用圆括号括起，序号标注于该式所在行 (当有续行时，应标注于最后一行) 的行末。公式可按章节顺序编号或按全文统一编号。公式序号必须连续，不得重复或跳缺。重复引用的公式不得另编新序号，本例共识采用按章编号。

$$m = \sum_{k=1}^{K} m_k \tag{3-1}$$

较长的公式，如必须转行时，最好在等号处转行, 如做不到这一点, 要在 $+, -, \times, \div$ 等数学符号处转

行。数学符号应写在转行处的行首。上下式尽可能在等号“=”处对齐。

$$\begin{aligned} f(x,y) = & f(0,0) + \frac{1}{1!}(x\frac{\partial}{\partial x} + y\frac{\partial}{\partial y})f(0,0) \\ & + \frac{1}{2!}(x\frac{\partial}{\partial x} + y\frac{\partial}{\partial y})^2 f(0,0) + K \\ & + \cdots \\ & + \frac{1}{n!}(x\frac{\partial}{\partial x} + y\frac{\partial}{\partial y})^n f(0,0) + K \end{aligned} \tag{3-2}$$

2. 多区模型

小鼠脑组织中的砷含量如图 1 所示，染 As 组小鼠脑组织中的砷含量高于对照组高于对照组高于对照组高于对照组高于对照组高于对照组高于对照组（$p < 0.05$）；染 $Hg + As$ 和染 $Gly + As$ 组小鼠脑组织中的砷含量低于染 As 组（$p < 0.05$）。

第四章　结论与展望

4.1　论文总结

本研究的目标是基于贝叶斯脑假设[3-7]研究动态环境中智能体的感知与学习。本文深入研究了智能体在动态环境中对不确定性的表征及高效学习与决策。研究受到认知神经科学中人类在动态环境下的决策行为及生物神经系统中神经元低阶交互的信息表征机制的启发，在贝叶斯脑假设下，... ... 本文主要开展了下述内容的研究：

1. 基于多尺度不确定性表征的感知模型：针对一般动态环境中不确定性表征问题，提出了一般层次化布朗滤波，... ...

2. 基于多元伯努利分布的动态环境不确定性表征与感知学习：动态地多元二值环境是神经科学中常用的实验环境。通常使用独立的多元伯努利分布描述多元二值的状态。... ...

3. 基于指数分布的动态环境不确定性表征与感知学习：动态地多元指数分布环境是神经科学中常用的实验环境。通常使用独立的多元指数分布描述环境的状态。一方面，如果智能体仅仅使用这个模型描述动态波动的环境，那么便丢失了对环境结构及率强度参数不稳定波动的理解能力。另一方面，... ...

4. 基于分类分布的动态环境不确定性表征与感知学习：为了表征分类分布，我们把其状态固定到一个多元高斯分布空间中考虑，每个状态的概率与其在多元高斯分布内的密度成正比。这样我们便把离散状态的不确定性转换成了多元高斯分布的中心位置及其不确定性。进一步地，... ...

5. 基于不确定性调节的自适应学习率机制：为了研究不确定性调节的自适应学习率，文中提出了基于高斯随机游走和伯努利分布的层次化贝叶斯模型，并且其学习率具有基于信念和环境不确定性所调节的自适应机制，能够有效且准确地推断动态二分类环境中的隐概率。在这个层次化贝叶斯模型中，隐状态的更新规则是具有恒定学习率的 Rescorla-Wagner 更新规则的扩展，... ...

本文在贝叶斯脑假设下立足于动态环境中自适应学习模型的构建，... ... 总之，本项研究内容新颖，具有较高的模型理论前瞻性和创新性，具有较好的应用前景和价值，其主要贡献和研究意义概括如下：

1. 提出了一般层次化布朗滤波：受到贝叶斯脑假设下层次化先验信念的表达及神经元集群中成对低阶交互的信息表征机制的启发，... ...

2. 提出了层次化布朗滤波及其变体模型的解析反演方案：针对一般层次化布朗滤波及其变体模型的反演，提出了一般层次化布朗滤波及其变体模型的变分反演方案，... ...

3. 提出了动态指数族分布环境下不确定性表征与学习方案: 针对动态指数族分布所描述的环境中不确定性感知与学习，提出了基于一般层次化布朗滤波的贝叶斯感知模型，... ...

4. 提出了一种基于不确定性的学习率调节机制: 主要针对动态环境下的学习机制问题，有效解决了智能体动态环境下学习率调节与形成问题，提高了智能体对环境的感知效率。... ...

4.2 未来工作展望

动态环境的认知建模对研究生物适应性行为及解析自适应性行为背后的机制至关重要。动态环境下，智能体需要高效的信息的处理机制，以应对复杂多变的动态环境。本文基于理论层面构建了动态环境下一般层次化布朗滤波。未来还有多个方向可以开展深入研究：

1. 认知实验：动态环境的不确定性表征和认知学习是考察生物智能体学习和认知特征的很好环境。依照本文提供的模型进行有针对的实验设计，有望解析出人类在复杂动态环境下的行为机制。

2. 神经网络模型：一般层次化布朗滤波为我们提供了一个很好的框架。基于这个框架我们可以构建更一般的神经网络模型。探索大脑执行贝叶斯推断的一般机制。

3. 自适应信息处理：本文提供了动态环境下不确定性的层次化表征，形成了自适应学习率更新规则。进一步解析动态学习率的调节机制，是下一步很好的研究方向。

参考文献

[1] Vossel S, Mathys C, Daunizeau J, et al. Spatial Attention, Precision, and Bayesian Inference: A Study of Saccadic Response Speed[J/OL]. Cerebral Cortex, 2014, 24(6): 1436-1450 [2021-11-03]. https://academic.oup.com/cercor/article-lookup/doi/10.1093/cercor/bhs418. DOI: 10.1093/cercor/bhs418.

[2] 蒋有绪, 郭泉水, 马娟等. 中国森林群落分类及其群落学特征[M]. 北京: 科学出版社, 1998.

[3] Beal M J. Variational algorithms for approximate Bayesian inference[D/OL]. University College London (UCL), 2003. https://discovery.ucl.ac.uk/id/eprint/10101435.

[4] Friston K. The free-energy principle: a unified brain theory?[J/OL]. Nature Reviews Neuroscience, 2010, 11(2): 127-138 [2020-11-27]. DOI: 10.1038/nrn2787.

[5] Daunizeau J, den Ouden H E M, Pessiglione M, et al. Observing the Observer (I): Meta-Bayesian Models of Learning and Decision-Making[J/OL]. PLOS ONE, 2010, 5(12): e15554 [2020-11-27]. https://dx.plos.org/10.1371/journal.pone.0015554. DOI: 10.1371/journal.pone.0015554.

[6] Daunizeau J, Ouden H E M d, Pessiglione M, et al. Observing the Observer (II): Deciding When to Decide [J/OL]. PLOS ONE, 2010, 5(12): e15555. DOI: 10.1371/journal.pone.0015555.

[7] Mathys C D, Daunizeau J, Friston K J, et al. A Bayesian Foundation for Individual Learning Under Uncertainty[J/OL]. Frontiers in Human Neuroscience, 2011, 5: 39. https://www.frontiersin.org/article/10.3389/fnhum.2011.00039. DOI: 10.3389/fnhum.2011.00039.

[8] 张贤达. 矩阵分析与应用[M]. 2 版. 北京: 清华大学出版社, 2013.

致　谢

我走了很远的路，吃了很多的苦，才将这份博士学位论文送到你的面前。二十二载求学路，一路风雨泥泞，许多不容易。如梦一场，仿佛昨天一家人才团聚过。

出生在一个小山坳里，母亲在我十二岁时离家。父亲在家的日子不多，即便在我病得不能自己去医院的时候，也仅是留下勉强够治病的钱后又走了。我十七岁时，他因交通事故离世后，我哭得稀里糊涂，因为再得重病时没有谁来管我了。同年，和我住在一起的婆婆病故，真的无能为力。她照顾我十七年，下葬时却仅是一副薄薄的棺材。另一个家庭成员是老狗小花，为父亲和婆婆守过坟，后因我进城上高中而命不知何时何处所终。如兄长般的计算机启蒙老师邱浩没能看到我的大学录取通知书，对我照顾有加的师母也在不惑之前匆匆离开人世。每次回去看他们，这一座座坟茔都提示着生命的每一分钟都弥足珍贵。

人情冷暖，生离死别，固然让人痛苦与无奈，而贫穷则可能让人失去希望。家徒四壁，在煤油灯下写作业或者读书都是晚上最开心的事。如果下雨，保留节目就是用竹笋壳塞瓦缝防漏雨。高中之前的主要经济来源是夜里抓黄鳝、周末钓鱼、养小猪崽和出租水牛。那些年里，方圆十公里的水田和小河都被我用脚测量过无数次。被狗和蛇追，半夜落水，因蓄电瓶进水而摸黑逃回家中；学费没交，黄鳝却被父亲偷卖了，然后买了肉和酒，都是难以避免的事。

人后的苦尚且还能克服，人前的尊严却无比脆弱。上课的时候，因拖欠学费而经常被老师叫出教室约谈。雨天湿漉着上课，屁股后面说不定还是泥。夏天光着脚走在滚烫的路上。冬天穿着破旧衣服打着寒颤穿过那条长长的过道领作业本。这些都可能成为压垮骆驼的最后一根稻草。如果不是考试后常能从主席台领奖金，顺便能贴一墙奖状满足最后的虚荣心，我可能早已放弃。

身处命运的漩涡，耗尽心力去争取那些可能本就是稀松平常的东西，每次转折都显得那么身不由己。幸运的是，命运到底还有一丝怜惜，进入高中之后，学校免了全部学杂费，胡叔叔一家帮助解决了生活费。进入大学之后，计算机终于成了我一生的事业与希望，胃溃疡和胃出血也终与我作别。

从家出发坐大巴需要两个半小时才能到县城，一直盼着走出大山。从炬光乡小学、大寅镇中学、仪陇县中学、绵阳市南山中学，到重庆的西南大学，再到中科院自动化所，我也记不清有多少次因为现实的压力而觉得自己快抗不下去了。这一路，信念很简单，把书念下去，然后走出去，不枉活一世。世事难料，未来注定还会面对更为复杂的局面。但因为有了这些点点滴滴，我已经有勇气和耐心面对任何困难和挑战。理想不伟大，只愿年过半百，归来仍是少年，希望还有机会重新认识这个世界，不辜负这一生吃过的苦。最后如果还能做出点让别人生活更美好的事，那这辈子就赚了。

此致谢仅用作测试样例，其原作者为：**中国科学院自动化研究所博士研究生　黄国平**

朱昌波

附录 A　矩阵分析

本附录章节概括了一些本文所用到的矩阵代数论，其中所有定理和定义的更详细信息均可参见文献[8]。

A.1　向量变元的梯度

向量变元 $\boldsymbol{x}$ 的标量值函数 $f:\mathbb{R}^d \mapsto \mathbb{R}$ 就是把任意向量变元 $\boldsymbol{x}\in\mathbb{R}^d$ 映射到实数轴上唯一的点 y，即 $y=f(\boldsymbol{x})$。接着，可以定义实值函数相对于（列）向量变元的梯度。

定义 A-1 (实值函数相对于列向量的梯度)**.** 实值函数 $f(\boldsymbol{x})$ 相对于列向量 $\boldsymbol{x}\in\mathbb{R}^d$ 的梯度是一个列向量，其第 i 个分量是函数 f 相对于列向量 $\boldsymbol{x}$ 的第 i 个分量元素的偏导数，即

$$\nabla_{\boldsymbol{x}} f(\boldsymbol{x})=\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}}=\left[\frac{\partial f}{\partial x_1},\frac{\partial f}{\partial x_2},\cdots,\frac{\partial f}{\partial x_d}\right]^{\top}$$

然后，实值函数相对于行向量的梯度可如下定义，

定义 A-2 (实值函数相对于行向量的梯度)**.** 实值函数 $f(\boldsymbol{x})$ 相对于行向量 $\boldsymbol{x}^{\top}\in\mathbb{R}^d$ 的梯度是一个行向量，其第 i 个分量是函数 f 相对于行向量 $\boldsymbol{x}^{\top}$ 的第 i 个分量元素的偏导数，即

$$\nabla_{\boldsymbol{x}^{\top}} f(\boldsymbol{x})=\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}^{\top}}=\left[\frac{\partial f}{\partial x_1},\frac{\partial f}{\partial x_2},\cdots,\frac{\partial f}{\partial x_d}\right]$$

向量变元 $\boldsymbol{x}\in\mathbb{R}^d$ 的梯度负向称为**梯度流**，记为 $\dot{\boldsymbol{x}}=-\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}}$。若函数 $f_i(\boldsymbol{x}), 1\le i\le m$ 是向量变元 $\boldsymbol{x}\in\mathbb{R}^d$ 的实值函数，那么函数 $\boldsymbol{f}(\boldsymbol{x})=[f_1(\boldsymbol{x}),f_2(\boldsymbol{x}),\ldots,f_m(\boldsymbol{x})]^{\top}$ 是向量变元 $\boldsymbol{x}$ 的向量值函数。进一步地，基于定义A-1及定义A-2，向量值函数 $\boldsymbol{f}(\boldsymbol{x})$ 相对于向量变元 $\boldsymbol{x}$ 的梯度可由下式定义

$$\begin{aligned}\frac{\partial \boldsymbol{f}^{\top}(\boldsymbol{x})}{\partial \boldsymbol{x}}=&\nabla_{\boldsymbol{x}}\boldsymbol{f}(\boldsymbol{x})=\left[\frac{\partial f^{(1)}}{\partial \boldsymbol{x}},\frac{\partial f^{(2)}}{\partial \boldsymbol{x}},\ldots,\frac{\partial f^{(m)}}{\partial \boldsymbol{x}}\right]\\ =&\begin{bmatrix}\frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} & \cdots & \frac{\partial f_n}{\partial x_1}\\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_2}\\ \vdots & \vdots & & \vdots\\ \frac{\partial f_1}{\partial x_m} & \frac{\partial f_2}{\partial x_m} & \cdots & \frac{\partial f_n}{\partial x_m}\end{bmatrix}\in\mathbb{R}^{m\times n}\end{aligned}$$

全微分为 $\mathrm{d}\boldsymbol{f}=(\frac{\partial \boldsymbol{f}^{\top}}{\partial \boldsymbol{x}})^{\top}\mathrm{d}\boldsymbol{x}$。

实值函数 $f(\boldsymbol{x})$ 相对于向量 $\boldsymbol{x}$ 的梯度满足下列性质，

(1) 若 $f(\boldsymbol{x})=c$ 为常数，那么 $\nabla_{\boldsymbol{x}} f(\boldsymbol{x})=\boldsymbol{0}$。

(2) 线性法则：若 $f(\boldsymbol{x})$ 和 $g(\boldsymbol{x})$ 均是 $\boldsymbol{x}$ 的实值函数，c_1,c_2 为常数，那么

$$\frac{\partial[c_1 f(\boldsymbol{x})+c_2 g(\boldsymbol{x})]}{\partial \boldsymbol{x}}=c_1\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}}+c_2\frac{\partial g(\boldsymbol{x})}{\partial \boldsymbol{x}}$$

(3) 乘法规则：若 $f(\boldsymbol{x})$ 和 $g(\boldsymbol{x})$ 均是 $\boldsymbol{x}$ 的实值函数，那么

$$\frac{\partial[f(\boldsymbol{x})g(\boldsymbol{x})]}{\partial \boldsymbol{x}} = f(\boldsymbol{x})\frac{\partial g(\boldsymbol{x})}{\partial \boldsymbol{x}} + g(\boldsymbol{x})\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}}$$

(4) 商式法则：若 $f(\boldsymbol{x})$ 和 $g(\boldsymbol{x}) \neq 0$ 均是 $\boldsymbol{x}$ 的实值函数，那么

$$\frac{\partial[\frac{f(\boldsymbol{x})}{g(\boldsymbol{x})}]}{\partial \boldsymbol{x}} = \frac{g(\boldsymbol{x})\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}} - f(\boldsymbol{x})\frac{\partial g(\boldsymbol{x})}{\partial \boldsymbol{x}}}{g(\boldsymbol{x})^2}$$

(5) 链式法则：若 $f(\boldsymbol{y})$ 是向量 $\boldsymbol{y}$ 的实值函数, 并且 $\boldsymbol{y}$ 是向量变元 $\boldsymbol{x}$ 的向量值函数，那么

$$\frac{\partial f}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}^\top}{\partial \boldsymbol{x}}\frac{\partial f(\boldsymbol{y})}{\partial \boldsymbol{y}}$$

(6) 若向量 $\boldsymbol{a}$ 与 $\boldsymbol{x}$ 是无关的向量，那么

$$\frac{\partial \boldsymbol{a}^\top \boldsymbol{x}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{x}^\top \boldsymbol{a}}{\partial \boldsymbol{x}} = \boldsymbol{a}$$

(7) $\frac{\partial \boldsymbol{x}^\top}{\partial \boldsymbol{x}} = \boldsymbol{I}$ 是单位矩阵。

(8) 线性映射的梯度：若 $\boldsymbol{W}, \boldsymbol{b}$ 分别是矩阵和常向量，$\boldsymbol{x}$ 是向量变元，则线性映射 $\boldsymbol{y} = \boldsymbol{W}\boldsymbol{x} + \boldsymbol{b}$ 的梯度矩阵为

$$\frac{\partial \boldsymbol{y}^\top}{\partial \boldsymbol{x}} = \boldsymbol{W}$$

(9) 若向量 $\boldsymbol{a}$ 与 $\boldsymbol{x}$ 是相关的向量，且 $\boldsymbol{y}$ 是向量 $\boldsymbol{x}$ 的向量值函数，那么

$$\frac{\partial \boldsymbol{a}^\top \boldsymbol{y}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}^\top \boldsymbol{a}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}^\top}{\partial \boldsymbol{x}}\boldsymbol{a}$$

(10) 若矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{y}$ 均与向量 $\boldsymbol{x}$ 是无关的，那么

$$\frac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{y}}{\partial \boldsymbol{x}} = \boldsymbol{A}\boldsymbol{y}, \frac{\partial \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{x}}{\partial \boldsymbol{x}} = \boldsymbol{A}^\top \boldsymbol{y}$$

(11) 若矩阵 $\boldsymbol{A}$ 与向量 $\boldsymbol{x}$ 是无关的，那么

$$\frac{\partial \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}}{\partial \boldsymbol{x}} = (\boldsymbol{A} + \boldsymbol{A}^\top)\boldsymbol{x}$$

(12) 若矩阵 $\boldsymbol{A}$ 与向量 $\boldsymbol{x}$ 是无关的，而向量 $\boldsymbol{y}$ 是向量 $\boldsymbol{x}$ 的向量值函数，那么

$$\frac{\partial \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{y}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}^\top}{\partial \boldsymbol{x}}(\boldsymbol{A} + \boldsymbol{A}^\top)\boldsymbol{y}$$

(13) 若矩阵 $\boldsymbol{A}$ 与向量 $\boldsymbol{x}$ 是无关的，而向量 $\boldsymbol{y}, \boldsymbol{z}$ 均是向量 $\boldsymbol{x}$ 的向量值函数，那么

$$\frac{\partial \boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{z}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{y}^\top}{\partial \boldsymbol{x}}\boldsymbol{A}\boldsymbol{y} + \frac{\partial \boldsymbol{z}^\top}{\partial \boldsymbol{x}}\boldsymbol{A}^\top \boldsymbol{z}$$